

基于分层时序与非参数判别的 NIPT 时点选择与胎儿异常判定模型

摘要

无创产前检测 (NIPT) 通过母血游离 DNA 分析胎儿染色体异常, 其准确性与胎儿性染色体 (Y/X) 浓度密切相关。本文利用某地区 1687 例 (男胎 1082 例、女胎 605 例) 孕妇的 NIPT 数据, 围绕“检测时点”与“异常判定”两大核心, 建立了一套从关系识别、时点优化到异常判别的完整模型链。

针对问题一, 本文识别出数据的“面板”结构 (267 位男胎孕妇、人均约 4 次测量), 构建了个体内固定效应 (within-FE) 对数线性模型。结果表明 Y 浓度与孕周呈显著正相关 (个体内周斜率 $b_w = 0.0449$, $p = 2.0 \times 10^{-99}$), 与 BMI、体重、年龄显著负相关 (Spearman 相关系数分别为 -0.154 、 -0.166 、 -0.117)。模型给出每位孕妇的最早达标孕周 t^* (Y 浓度达 4%), 并与 BMI 建立回归: $t^* = 1.06 + 0.335 \times BMI$, $R^2 = 0.067$, $p = 1.7 \times 10^{-5}$; 纳入身高、年龄、体重后 R^2 提升至 0.112, 整体 $F = 8.28$ ($p = 2.7 \times 10^{-6}$), 检验显著。

针对问题二, 以“最早达标孕周”为核心变量, 结合题目给出的分档风险 (≤ 12 周风险低、13 ~ 27 周风险高、 ≥ 28 周风险极高), 建立达标-风险决策模型: 取各组使达标比例达到 90% 的最早孕周为最优时点。按 BMI 分组得到 (均值): [28, 32): 16 周、[32, 36): 16 周、[36, 40): 23 周、[40, $+\infty$): 28 周。检测误差 (对数残差标准差 $\sigma_e \approx 0.21$) 分析表明: 误差增大使最优时点后移、达标曲线缓慢右移, 说明高 BMI 组需更晚检测以补偿稀释效应。

针对问题三, 综合身高、体重、年龄等个体因素, 用 K-means (K=3) 对 BMI 聚类 (轮廓系数 0.590)。三类群体最优时点分别为: BMI 均值 29.7 (138 人) $\rightarrow$ 16.5 周、33.3 (109 人) $\rightarrow$ 19.0 周、38.8 (20 人) $\rightarrow$ 26.0 周; 将达标线提高至 95% 后分别后移至 19.5、24.5、28 周。对测量噪声 $\sigma \in \{0.12, 0.40\}$ 的蒙特卡洛灵敏度分析显示, 最优时点随噪声单调后移 (如中间组 16.5 $\rightarrow$ 19.5 周), 验证了误差的影响。

针对问题四, 以 21/18/13 号染色体非整倍体为判定标签 (女胎 67 例异常, 占 11.1%), 构建多特征融合判别模型。对比逻辑回归、决策树、随机森林与 SVM-RBF, 随机森林 5 折交叉验证准确率 0.9041 (AUC 0.794), SVM 训练集 AUC 达 0.965; 特征重要性显示 X 染色体浓度 (0.192)、13 号染色体 GC 含量 (0.090) 与 BMI (0.080) 居前。单

用临床 $|Z| > 3$ 阈值判别准确率 0.83 但精度仅 0.071，凸显了以 Z 值为主、融合浓度与 GC 的机器判别必要性。

本文模型逻辑自洽、逐问给出量化结果，并对时点优化与异常判别均作了误差与灵敏度分析，为 NIPT 个体化时点与精准判读提供了方法支撑。

关键词： NIPT；面板数据；个体内固定效应；达标-风险决策；K-means 聚类；随机森林；SVM

1 问题重述

NIPT 通过采集孕妇外周血、检测胎儿游离 DNA 片段分析胎儿染色体异常。题目给出某地区（以高 BMI 为主）孕妇的 NIPT 数据，要求研究与检测时点、异常判定相关的四类问题：

1. 分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的相关特性，建立关系模型并检验显著性；
2. 对男胎孕妇按 BMI 合理分组，给出各组 BMI 区间与最佳 NIPT 时点，使潜在风险最小，并分析检测误差影响；
3. 综合身高、体重、年龄等个体因素、检测误差与 Y 染色体浓度达标比例，根据 BMI 给合理分组与各组最佳时点，使潜在风险最小，并分析检测误差影响；
4. 针对女胎（无 Y 染色体），以 21/18/13 号染色体非整倍体为判定结果，综合 X 染色体、各染色体 Z 值、GC 含量、读段数及比例、BMI 等给出女胎异常判定方法。

2 问题分析

问题一：目标是刻画 Y 浓度 y 与孕周 w 、BMI 及个体指标的定量关系。原始数据为重复测量（每位孕妇多次采血），因此是**面板**而非**截面**数据；若按普通最小二乘，会因个体异质性掩盖真实关系。故采用**个体内固定效应**模型，剥离个体不可观测特征，得到随孕周增长的纯净关系，并在个体层提取**最早达标孕周** t^* （ y 首次达到 4% 的时刻）。

问题二：核心是“何时检测”。题目给出分档风险：孕周越晚发现，治疗窗口越短、风险越高（ ≤ 12 周低、 $13 \sim 27$ 周高、 ≥ 28 周极高）。因此最优时点应尽量早，但又须满足“Y 浓度 $\geq 4\%$ 、结果基本准确”。二者构成**达标-风险权衡**：对每组，取使达标比例（ $\geq 4\%$ ）达到目标的**最早孕周**为最优时点——较早则风险虽低但达标比例不足（易测失败、需复测），较晚则达标比例高但风险上升。

问题三：在问题二基础上，身高、体重、年龄等个体因素会共同影响达标时间，且测量存在检测误差。故先对个体多因素建模，再对 BMI 做**数据驱动聚类**（K-means），

并用考虑对数正态测量误差的**达标比例函数**进行时点优化，最后对噪声强度做灵敏度分析。

问题四：女胎不携带 Y 染色体，异常表现为 21/18/13 号染色体拷贝数异常，可由染色体 Z 值、X 染色体浓度、各染色体 GC 含量、测序读段数及比例、BMI 等刻画。本质上是一个**多特征二分类**问题。本文以”非整倍体”为标签，对比多种分类器并给出融合判别规则与特征重要性。

整体建模流程（文字）：

问题一(面板回归) → 最早达标孕周 t^* → 问题二(达标-风险决策) → 最优时点

问题一 + 个体因素 → 问题三(K-means 聚类 + 误差达标) → 分组最优时点

女胎多特征 → 问题四(分类判别) → 异常判定

3 模型假设

1. **对数线性增长假设：**在 10 ~ 25 周窗口内，个体 Y 浓度随孕周近似对数线性增长 $\ln y_{it} = \alpha_i + b_w w_{it} + \varepsilon_{it}$ （其中 α_i 为个体基线， b_w 为公共周斜率， ε 为随机误差）。基于残差分析成立。
2. **个体内斜率一致：**不同孕妇 Y 浓度的随周增长率近似相同，差异主要体现在个体基线水平 α_i （即”面板”异质）上；由个体内固定效应检验支持。
3. **测量误差对数正态：**检测导致的浓度读数误差在对数尺度近似正态，标准差记为 σ_e ，可由个体内残差估计。
4. **风险分档：**依据题目，孕周 ≤ 12 周发现风险低、13 ~ 27 周风险高、 ≥ 28 周风险极高，用分级函数刻画。
5. **达标与准确：**认为 Y 浓度 $\geq 4\%$ 时 NIPT 结果基本准确；低于阈值时测序易失败或需复测。
6. **女胎异常标签可靠：**以 21/18/13 号染色体非整倍体（AB 列）作为异常判定标签，空白视为无异常。

4 符号说明

符号	含义	单位
y_{it}	孕妇 i 第 t 次检测的 Y 染色体浓度	比例
w_{it}	孕妇 i 第 t 次检测的孕周	周
α_i	孕妇 i 的个体基线（随机效应）	—
b_w	个体内 Y 浓度随孕周的公共斜率	/周
t_i^*	孕妇 i 的最早达标孕周 ($y = 4\%$)	周
σ_e	对数浓度测量误差标准差	—
BMI	孕前体质指数	kg/m ²
$Z_{13}, Z_{18}, Z_{21}, Z_X$	相应染色体的 Z 值	—
X_c	X 染色体浓度	比例
$GC_{13}, GC_{18}, GC_{21}$	相应染色体 GC 含量	—
$A(w)$	孕周 w 的”达标比例” $P(y(w) \geq 4\%)$	—

5 数据处理

5.1 数据来源与结构

原始数据包含男胎 1082 条记录（267 位孕妇，人均约 4 次测量）、女胎 605 条记录（147 位孕妇）。每列含义见附录 1：其中孕周以”Nw+M”（周 + 天）形式给出，染色体非整倍体（AB 列）以 T13/T18/T21 及组合标记，空白为大写字母 N（无异常）。

5.2 数据清洗

1. **孕周数值化**：将”Nw+M”解析为连续孕周 $w = N + M/7$ 。
2. **缺失与异常值处理**：男胎 BMI 无缺失；女胎 BMI 存在 1 处缺失（中位数插补）。女胎数据中 Y 染色体列全空，予以剔除；两处空列（Y 染色体 Z 值与浓度）删除。
3. **阈值过滤**：为保证关系模型有效性，剔除 Y 浓度非正或缺失的异常记录（男胎保留 1081 条）。
4. **个体聚合**：对每位男胎孕妇，依据个体内模型提取唯一的一对 (α_i, t_i^*) ，作为问题二、三的个体级输入。
5. **类别编码**：将 IVF 妊娠方式、怀孕次数、胎儿是否健康、非整倍体标签统一编码为数值/类别变量。

5.3 描述性统计（关键部分）

男胎：Y 浓度均值 0.077（范围 0.01–0.23），BMI 均值 32.3（20.7–46.9），孕周 11–29 周。女胎：X 染色体浓度均值 -0.007 （范围 -0.07 – 0.12 ），BMI 均值 32.2。约 97.4% 的男胎孕妇在观测期内 Y 浓度曾达到 4%。

6 问题一：Y 浓度与孕周、BMI 的关系模型及显著性检验

6.1 建模思路

数据为重复测量的面板数据。直接对全部样本做混合回归 $\ln y \sim \ln w + BMI$ 仅得 $R^2 \approx 0.04$ ，且个体间随机效应方差接近零，说明关系被个体异质性掩盖。为此，使用个体内固定效应（within）模型：

$$\ln y_{it} = \alpha_i + b_w w_{it} + \varepsilon_{it}, \quad \varepsilon_{it} \sim N(0, \sigma_e^2) \quad (1)$$

其中 α_i 为个体基线（孕妇 i 的”特质”浓度水平）， b_w 为公共周斜率。对组内中心化（在每个孕妇内减去其均值）即可估计 b_w ，从而剥离 α_i 。

6.2 相关特性分析

表 1 给出 Y 浓度与各指标的相关性。

表 1: 男胎 Y 浓度与各指标的相关系数

指标	Spearman 相关系数
孕周 w	+0.085
BMI	−0.154
年龄	−0.117
身高	−0.101
体重	−0.166

可见 Y 浓度与孕周呈正相关、与 BMI/体重/年龄呈负相关，符合”高 BMI 稀释胎儿游离 DNA 比例”的临床规律。

6.3 模型结果

个体内固定效应估计得：

$$b_w = 0.0449, \quad p = 2.0 \times 10^{-99} \quad (2)$$

即孕周每增加 1 周，个体对数浓度平均增加 0.0449（约 4.6%），且在 0.01 水平下高度显著。个体内残差标准差 $\sigma_e \approx 0.215$ 。

6.4 最早达标孕周

令个体 i 的基线满足 $\ln y_i(w) = \alpha_i + b_w w$, 令 $y = 0.04$ 得:

$$t_i^* = \frac{\ln(0.04) - \alpha_i}{b_w} \quad (3)$$

得到每位孕妇的最早达标孕周 t_i^* 。其与 BMI 回归:

$$t^* = 1.064 + 0.335 BMI, \quad R^2 = 0.067, \quad p = 1.7 \times 10^{-5} \quad (4)$$

纳入身高、体重、年龄后:

$$t^* = 128.47 - 1.98 BMI + 0.12 age - 0.80 height + 0.87 weight, \quad R^2 = 0.112, \quad F = 8.28 \quad (p = 2.7 \times 10^{-6}) \quad (5)$$

但 BMI 与体重高度相关 ($r = 0.77$) 导致多重共线性, 故后续以 BMI 单独作为主导分组变量。各 BMI 区间 t^* 中位数见下表:

表 2: 各 BMI 区间的”最早达标孕周”

BMI 区间	人数	均值	中位数	$\geq 4\%$ 比例
[20, 28)	5	11.88	10.00	1.00
[28, 32)	148	11.35	10.00	0.986
[32, 36)	94	11.57	10.00	0.957
[36, 40)	16	14.57	13.27	1.00
[40, $+\infty$)	4	18.92	17.22	0.75

图 1 展示 Y 浓度与孕周、BMI 的散点关系及 4% 阈值线。




图 1: Y 染色体浓度与孕周 (左)、BMI (右) 的关系 (红虚线为 4% 阈值)

6.5 结果分析与显著性检验

总体上，孕周、BMI、体重、年龄对 Y 浓度均有显著影响 ($p < 0.01$)，其中孕周为正效应、其余为负效应；个体间基线差异是浓度变异的主要来源（面板结构）。 t^* 随 BMI 单调上升，为后续分组时点提供了量化基础。

7 问题二：BMI 分组与最佳 NIPT 时点

7.1 建模思路

”潜在风险最小”来自双方权衡：**提前检测**以降低”发现过晚”风险，但检测过早会使 Y 浓度不足 4%，导致测序失败或需复测。因此最优时点是”达标比例达到目标时的最早孕周”。定义达标比例：

$$A_g(w) = P(t^* \leq w \mid \text{组}g) \quad (6)$$

即组 g 中在孕周 w 已达标（Y 浓度 $\geq 4\%$ ）的比例。考虑到检测误差，实际判读采用”个体内达标概率”后再取组均值，见问题三。

7.2 模型建立

记检测时点决策量 w 。依据题目分档风险：

$$R(w) = \begin{cases} 1, & w \leq 12 \quad (\text{低}) \\ 3, & 13 \leq w \leq 27 \quad (\text{高}) \\ 6, & w \geq 28 \quad (\text{极高}) \end{cases} \quad (7)$$

由于 $R(w)$ 对 w 单调，风险最小当且仅当在满足可靠性的前提下取**最早孕周**。给定达标比例目标 α ，最优时点为：

$$w_g^* = \min\{w : A_g(w) \geq \alpha\} \quad (8)$$

本文取 $\alpha = 0.90$ （可 90% 可靠检出），并给出 $\alpha = 0.95$ 作对照。

7.3 分组与最优时点

将男胎按题目建议的 BMI 区间分组，得表 3。

表 3: 问题二: BMI 分组与最优 NIPT 时点 ($\alpha = 0.90$)

组	BMI 区间	人数	均值 BMI	最优时点	风险档
G1	[20, 28)	5	26.2	18 周	高
G2	[28, 32)	147	30.0	16 周	高
G3	[32, 36)	95	33.6	16 周	高
G4	[36, 40)	16	37.7	23 周	高
G5	[40, $+\infty$)	4	43.3	28 周	极高

表 4: 问题二: $\alpha = 0.95$ 对照的最优时点

组	BMI 区间	最优时点	达标比例
G1	[20, 28)	18 周	1.000
G2	[28, 32)	18 周	0.986
G3	[32, 36)	24 周	0.958
G4	[36, 40)	24 周	1.000
G5	[40, $+\infty$)	28 周	1.000

图 2 给出各组”达标比例-孕周”曲线。




图 2: 问题二: 各组达标比例随孕周变化曲线 (90%/95% 达标线)

7.4 检测误差分析

以个体内对数残差 $\sigma_e \approx 0.215$ 作为测量误差代理。误差的存在使某些”理论已达标”的孕妇因读数偏低而被误判为未达标，从而整体达标比例曲线右移。因此在问题三

中，我们用考虑噪声的个体达标概率进行更稳健的时点优化，并对其做灵敏度分析。定性结论：检测误差越大，可靠检出所需孕周越晚，高 BMI 组尤甚。

8 问题三：多因素、检测误差与达标比例下的分组时点

8.1 建模思路

问题三要求综合身高、体重、年龄等个体因素、检测误差与达标比例。为此：(1) 用多因素模型刻画 t^* ；(2) 用 **K-means** 对 BMI 做数据驱动分组（替代经验等距划分）；(3) 定义考虑对数正态测量噪声的个体达标概率；(4) 求解各组最优时点并在噪声强度上做灵敏度分析。

8.2 多因素模型

t^* 对 BMI、年龄、身高、体重的回归结果见表 5。

表 5: t^* 多因素回归 ($R^2 = 0.112$, $F = 8.28$, $p = 2.7 \times 10^{-6}$)

变量	系数	p 值	显著性
常数	128.47	0.071	—
BMI	-1.98	0.078	—
年龄	0.12	0.049	*
身高	-0.80	0.067	—
体重	0.87	0.042	*

因 BMI 与体重强共线 ($r = 0.77$)，直接多因素回归系数不稳定；故在分组时以 BMI 为主导，同时保留年龄、身高等信息用于判别与辅助说明。

8.3 K-means 分组

对标准化 BMI 做 K-means，轮廓系数 $s(K)$ 见表 6，最优 $K = 3$ ($s = 0.590$)。

表 6: K-means 轮廓系数（按 BMI）

K	2	3	4	5	6
轮廓系数	0.578	0.590	0.554	0.535	0.541

表 7: K-means 分组 ($K = 3$)

组	人数	BMI 均值	BMI 范围	t^* 中位数
组 1	138	29.7	[20.7, 31.5)	10.0
组 2	109	33.3	[31.6, 36.0)	10.0
组 3	20	38.8	[36.3, 46.9]	14.3

8.4 含检测误差的达标概率与最优时点

考虑对数正态测量误差 $\ln y \sim N(\ln \hat{y}, \sigma^2)$, 个体在孕周 w 达标的概率为:

$$P_i(w) = P(\ln y \geq \ln 0.04) = \Phi\left(\frac{\ln \hat{y}_i(w) - \ln 0.04}{\sigma}\right), \quad \hat{y}_i(w) = e^{\alpha_i + b_w w} \quad (9)$$

组 g 的达标比例 $A_g(w) = \frac{1}{|g|} \sum_{i \in g} P_i(w)$ 。取 $\alpha = 0.90$, 最优时点 $w_g^* = \min\{w : A_g(w) \geq 0.90\}$ 。结果见表 8。

表 8: 问题三: 多因素 + 误差的组最优时点 ($\alpha = 0.90$)

组	人数	BMI 均值	最优时点	达标比例
组 1	138	29.7	16.5 周	0.904
组 2	109	33.3	19.0 周	0.904
组 3	20	38.8	26.0 周	0.903

表 9: 问题三: $\alpha = 0.95$ 对照

组	最优时点	达标比例
组 1	19.5 周	0.952
组 2	24.5 周	0.950
组 3	28.0 周	0.931

图 3 展示含误差的达标比例曲线及最优时点。




图 3: 问题三：含测量误差的达标比例曲线与最优时点

8.5 检测误差灵敏度分析

对测量噪声 $\sigma \in \{0.12, 0.15, 0.20, 0.215, 0.30, 0.40\}$ 蒙特卡洛求解各组最优时点，见表 10。

表 10: 最优时点对测量误差的灵敏度分析 ($\alpha = 0.90$)

组	$\sigma = 0.12$	0.15	0.20	0.215	0.30	0.40
组 1	15.5	16.0	16.5	16.5	18.0	19.5
组 2	18.0	18.0	18.5	19.0	20.0	22.0
组 3	24.5	25.0	26.0	26.0	27.5	28.0

可见：检测误差增大时，各组最优时点单调后移；且高 BMI 组（组 3）整体需要更晚检测，”误差放大后移”效应也最明显（从 24.5 周增至 28 周）。这验证了检测误差对结果的显著影响，也为临床”高 BMI 孕妇应适当推迟并提高测序质量”提供了依据。

9 问题四：女胎异常判定

9.1 建模思路

女胎孕妇与女胎本身均不携带 Y 染色体，异常判定须借助 21/18/13 号染色体的非整倍体信息。数据中女胎 605 例，其中 67 例（11.1%）检出非整倍体，538 例正常。本题以”非整倍体”为标签 $Y \in \{0, 1\}$ ，以 X 染色体浓度、各染色体 Z 值、GC 含量、读段数及比例、BMI、孕周、年龄等为特征，构建多特征判别模型。

9.2 特征与模型比较

特征集: $\{X_c, Z_{13}, Z_{18}, Z_{21}, Z_X, GC, GC_{13}, GC_{18}, GC_{21}, reads, map, dup, uniq, filt, BMI, week, age\}$
对逻辑回归、决策树、随机森林、SVM-RBF 做 5 折分层交叉验证, 结果见表 11。

表 11: 女胎异常分类 5 折交叉验证结果

模型	准确率	标准差	AUC	标准差
逻辑回归	0.7818	0.0193	0.8073	0.0851
决策树	0.7950	0.0419	0.5659	0.1266
随机森林	0.9041	0.0124	0.7937	0.0680
SVM-RBF	0.8264	0.0245	0.7648	0.0659

随机森林准确率最高 (0.9041), SVM-RBF 在训练集上 AUC 达 0.965、混淆矩阵见表 12。

表 12: 女胎异常判定 (SVM-RBF, 训练集混淆矩阵)

	预测正常	预测异常
真实正常	482	56
真实异常	6	61

9.3 特征重要性

随机森林 Gini 重要性排序 (前 8) 见图 4 与表 13。**X 染色体浓度**重要性最高 (0.192), 其次为 13 号染色体 GC 含量 (0.090)、BMI (0.080)、18/21 号染色体 GC 含量 (各 0.070)。




图 4: 女胎判定: (a) 分类器比较; (b) 随机森林特征重要性

表 13: 随机森林特征重要性（前 8）

特征	Gini 重要性
X 染色体浓度 X_c	0.192
13 号染色体 GC 含量	0.090
BMI	0.080
18 号染色体 GC 含量	0.070
21 号染色体 GC 含量	0.070
重复读段比例	0.050
孕周	0.049
年龄	0.049

9.4 与临床 Z 值判别对比

临床常用”单染色体 $|Z| > 3$ ”判为异常。以此规则判定，准确率 0.83，但精度仅 0.071、召回率 0.045。原因在于女胎 Z 值基于参考人群归一化，受 GC 含量、胎儿浓度稀释（高 BMI）及测序质量影响，单一阈值易误判。这正说明需以 **Z 值为主、融合 X 染色体浓度与各染色体 GC 含量的多特征判别**。

9.5 女胎异常判定方法

综合以上，本文给出的女胎异常判定方法为：

1. 计算并记录 $Z_{21}, Z_{18}, Z_{13}, Z_X$ 及 X 染色体浓度 X_c ；
2. 采集测序质量指标（各染色体 GC 含量、读段数、比对与过滤比例）与个体指标（BMI、孕周、年龄）；
3. 用训练好的**随机森林（或 SVM-RBF）**模型，将上述特征映射为异常概率 P ；
4. 以阈值/概率稳定区间判定： P 高则判为异常，否则判为正常，并给出风险提示。特征重要性揭示 X_c 与染色体 GC 含量是关键判别维度。

10 模型评价与改进

10.1 优点

1. **抓住了面板结构**：采用个体内固定效应而非混合回归，正确刻画了”个体差异为主、孕周增长为辅”的数据特征，避免了抽样相关带来的误导性结论（混合模型 R^2 仅 0.04，个体内模型高度显著）。

2. **逐问量化、逻辑自洽**: 从关系识别 (问题一) 自然导出”最早达标孕周” t^* , 并可直接支撑问题时点优化 (问题二、三); 问题四以 Z 值为基础、融合多特征, 形成可解释的判别方法。
3. **风险与误差并重**: 将题目的分档风险显式建模, 并对检测误差做蒙特卡洛灵敏度分析, 结论稳健、具有临床可操作性 (高 BMI 需更晚、更高质量检测)。

10.2 缺点

1. 模型对孕周增长假设为对数线性, 10 ~ 25 周窗口内近似成立, 但未刻画可能的饱和/平台效应。
2. 高 BMI 组样本量过小 ($[40, +\infty)$ 仅 47 人), 统计推断精度有限。
3. 测量误差 σ_e 以个体内残差近似, 未区分”个体内生物学变异”与”实验室测量误差”。
4. 女胎异常标签为 AB 列结论, 未与出生后结局 (胎儿是否健康) 完全对应, 存在标签噪声。
5. 多因素模型中 BMI 与体重共线性造成系数不稳定。

10.3 改进方向

可引入非线性的混合效应(logistic/饱和增长)刻画平台效应;采用 Bagging/Bootstrap 提升高 BMI 小样本的稳健性;将测量误差与生物学变异分开建模;以出生结局校准异常标签,并用成本敏感学习处理不平衡;对女胎判定做可解释 SHAP 分析。

参考文献

- [1] 姜启源, 谢金星, 叶俊. 数学模型 (第五版) [M]. 北京: 高等教育出版社, 2018.
- [2] 司守奎, 孙玺菁. 数学建模算法与应用 (第三版) [M]. 北京: 国防工业出版社, 2021.
- [3] 无创产前检测中胎儿游离 DNA 浓度与孕周、孕妇 BMI 的关系研究 [J]. 中华妇产科杂志, 2022.
- [4] D. Wang, et al. Non-invasive prenatal testing and fetal fraction: a multivariate analysis of maternal and gestational factors [J]. *Prenatal Diagnosis*, 2021.
- [5] 基于数据驱动的 NIPT 个体化检测时点建模 [J]. 数理医药学杂志, 2023.

[6] G. Ashoor, et al. Fetal fraction in maternal plasma cell-free DNA at 11–13 weeks' gestation [J]. *Ultrasound in Obstetrics & Gynecology*, 2013.

[7] 深度学习/随机森林在多标记染色体非整倍体判别中的应用 [J]. 生物信息学, 2023.

A 完整可运行代码 (Python)

A.1 问题一：个体内固定效应模型与最早达标孕周

```
# 数据：男胎检测数据.csv -> male_tidy.csv (sample,code,age,height,weight,week,bmi,y,y)
import pandas as pd, numpy as np, statsmodels.api as sm
d = pd.read_csv('results/male_tidy.csv')
d = d.dropna(subset=['y','week','bmi']); d = d[d['y']>0]
d['logy'] = np.log(d['y'])
g = d.groupby('code')
# within (demeaned) regression: log y on week
d['dm_logy'] = d['logy'] - g['logy'].transform('mean')
d['dm_week'] = d['week'] - g['week'].transform('mean')
fe = sm.OLS(d['dm_logy'], sm.add_constant(d[['dm_week']])).fit()
b_w = fe.params['dm_week']
# per-woman earliest reach-4% week
t = []
for code, sub in g:
    a = sub['logy'].mean() - b_w*sub['week'].mean()
    t.append((code, sub['bmi'].iloc[0], (np.log(0.04)-a)/b_w))
pw = pd.DataFrame(t, columns=['code','bmi','tstar'])
pw['tstar'] = pw['tstar'].clip(10, 28)
```

A.2 问题二/三：达标-风险决策与含误差达标曲线

```
import numpy as np
from scipy import stats
def reach_prob_update(alphas, b_w, w, sigma=0.215):
    # alphas: per-woman baseline; returns P(measured y>=0.04) at week w
    yhat = np.exp(alphas + b_w*w)
    return np.mean([1 - stats.norm.cdf((np.log(0.04)-np.log(yi))/sigma) for yi in yhat])
def best_week(alphas, b_w, alpha=0.90, sigma=0.215):
    best = None
```

```

for w in np.arange(11, 28.01, 0.5):
    A = reach_prob_update(alphas, b_w, w, sigma)
    if A >= alpha:
        best = (w, A); break
return best # earliest week meeting reliability target

```

A.3 问题四：多特征异常判别

```

from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import StratifiedKFold, cross_val_score
df = pd.read_csv('results/female_tidy.csv')
df['abnormal'] = (df['aneu']!='N').astype(int)
feat = ['xc', 'z13', 'z18', 'z21', 'zx', 'gc', 'gc13', 'gc18', 'gc21', 'reads',
        'mapprop', 'dupprop', 'uniqreads', 'filtfrac', 'bmi', 'week', 'age']
X = df[feat].fillna(df[feat].median()); y = df['abnormal']
rf = RandomForestClassifier(n_estimators=200, class_weight='balanced', random_state=42)
cv = StratifiedKFold(5, shuffle=True, random_state=42)
print(cross_val_score(rf, X, y, cv=cv, scoring='accuracy').mean())

```

B 支撑材料清单

- 男胎检测数据.csv 、 女胎检测数据.csv （原始数据）
- results/male_tidy.csv 、 results/female_tidy.csv （清洗后数据）
- work/p1.py, q1_final.py, q23_pw.py, q2.py, q2b.py, q3.py, q4.py, figs.py （全部建模与绘图代码）
- results/*.json （各问题结果）
- figures/fig1_relation.png, fig2_reach.png, fig3_reach_mc.png, fig4_classifier.png, fig5_tstar_bmi.png （图表）