

NIPT 的时点选择与胎儿的异常判定

基于风险最小化分组与多因素浓度模型的研究

数学建模竞赛论文

摘要

针对无创产前检测 (NIPT) 的时点选择与女胎异常判定问题, 本文基于某地区 1075 例男胎检测记录 (267 名孕妇) 与 605 例女胎检测记录 (147 名孕妇), 建立了“浓度预测—风险递推—分组优化—异常判定”的完整建模体系。

问题 1: 以孕周 G 、BMI B 为解释变量, 经似然比与 BIC 比较确定对数线性关系模型 $\ln C = -6.319 + 0.0133G + 0.2356B - 0.00398B^2$ (各系数 $p < 10^{-4}$, HC3 稳健标准误); 混合效应模型进一步给出个体内纵向效应: 孕周每增加 1 周 Y 浓度相对提高约 4.3% ($p \approx 10^{-76}$), BMI 每增加 1 单位相对下降约 2.2% ($p = 0.002$)。

问题 2: 以“发现时点风险权重 + 复查代价”定义期望潜在风险, 反向递推求各 BMI 组最优首次检测时点。结果表明: BMI ≤ 38 的孕妇最优时点为可检测窗口起点 (10 周), 期望风险约 1.03、平均检测 1.27 次; BMI > 38 组最优时点约 10.25 周, 但期望风险升至 1.46、平均检测 2.2 次、达标率仅 53.5%, 且 BMI ≈ 45 时模型预测超过半数孕妇在 10–26 周内难以达标, 应及早联合侵入性检测。该结论在检测误差 (浓度变异系数 0–20%)、测序失败假设与复查间隔的敏感性分析下保持稳健。

问题 3: 引入体重、身高、年龄的扩展模型 $\ln C = -4.711 + 0.0136G + 0.0537W - 0.00037W^2 - 0.0111A$ ($R^2 = 0.082$, 年龄、体重显著, 身高不显著), 重新分组后结论与问题 2 一致 (人均期望风险 1.047 vs 1.044), 且个体化时点与组内统一时点几乎无差异, 说明本文的 BMI 分组方案对协变量调整和个体差异具有稳健性。

问题 4: 以 AB 列非整倍体检出为标签, 经典 $|Z| \geq 3$ 规则灵敏度仅 0–6%, 不适用本数据; 按孕妇分组的交叉验证下, logistic/随机森林对“任一异常”的 AUC 达 0.78, T13 达 0.83, T18 达 0.79; 最终给出标准化 logistic 判定得分, 显著因素为 X 染色体浓度、21/13 号染色体 GC 含量、X 染色体 Z 值、年龄与被过滤读段比例, 全数据 AUC 0.861 (Youden 阈值下灵敏度 0.716、特异度 0.883)。T21 标签在当前特征下无可学习信号, 如实报告并建议联合其他平台复核。

关键词: NIPT; Y 染色体浓度; 混合效应模型; 风险最小化; 动态规划分组; 非整倍体判定

1 问题重述与分析思路

NIPT 通过母体血浆中胎儿游离 DNA 片段比例 (染色体浓度) 判断胎儿染色体是否异常。男胎以 Y 染色体浓度 $\geq 4\%$ 作为结果可靠性的门槛; 女胎不携带 Y 染色体, 需借助 13/18/21 号染色体的 Z 值、GC 含量、读段数比例等指标判定非整倍体。附件提供男胎 1082 条、女胎 605 条检测记录 (同一孕妇含多次采血/多次检测), 要求: (1) 建立 Y 浓度与孕周、BMI 的关系模型并

检验显著性；(2) 对男胎孕妇 BMI 分组并给出各组最佳 NIPT 时点使潜在风险最小，分析检测误差影响；(3) 综合身高、体重、年龄等因素重复 (2)；(4) 给出女胎异常的判定方法。

建模主线：先用混合效应回归刻画浓度的群体与个体内规律（问题 1）；再把”风险”量化为发现时点风险权重与复查代价的期望，反向递推得到任意时点的期望风险，进而以带最小样本量约束的一维动态规划搜索 BMI 最优分组（问题 2、3）；最后以监督分类与可解释逻辑回归建立女胎判定规则（问题 4）。

2 模型假设

1. 检测孕周以附件”周 + 天”记录为准，换算为十进制周；同一孕妇的多次检测视为重复测量，用随机截距刻画个体异质性。
2. Y 浓度服从对数正态误差结构（对数尺度残差近似同方差，异方差用 HC3 稳健标准误处理）。
3. 单次检测”有效”需测序成功且 $C \geq 4\%$ ；测序失败概率随检测过早而升高，取 $p_{\text{fail}}(t) = 0.02 + 0.06e^{-0.5(t-10)}$ （量级与文献报道的高 BMI 人群无创失败率一致 [1, 2]），并作敏感性分析。
4. 检测无效时按间隔 $\delta = 2$ 周复查（文献建议低浓度后 3-4 周重采血 [2]，本文取 2 周并做 1-3 周敏感性分析）。
5. 题目给定”12 周以内低风险、13-27 周高风险、28 周以后极高风险”，为使其可优化，取连续化分段线性权重

$$w(t) = \begin{cases} 1, & t \leq 12, \\ 1 + 2(t - 12)/15, & 12 < t \leq 27, \\ 3 + 3(t - 27), & t > 27. \end{cases}$$

6. 分组在临床上须有足够样本支撑，动态规划中每组样本数 ≥ 40 。

3 符号说明

符号	含义
$C, \ln C$	Y 染色体浓度及其对数
G, B	检测孕周（周）、孕妇 BMI (kg/m^2)
W, H, A	体重 (kg)、身高 (cm)、年龄 (岁)
β	回归系数； $u_m \sim N(0, \tau^2)$ 孕妇随机截距
τ^2, σ^2	个体间、个体内（含测量）方差， $s^2 = \tau^2 + \sigma^2$
$p_{\text{valid}}(t, b)$	时点 t 、BMI b 下检测有效的概率
$R(t)$	首次检测定于 t 时的期望潜在风险
δ, λ	复查间隔、每次复查附加代价
Z_k, GC_k	k 号染色体 Z 值、GC 含量

4 数据预处理与描述

男胎原始 1082 条记录中, 1 条关键变量缺失、6 条为极端离群 (Y 浓度 $> 20\%$ 或孕周超界), 清洗后 1075 条, 来自 267 名孕妇, 人均 4.03 次检测; 女胎 605 条、147 名孕妇。用身高体重复算 BMI 与附件一致 (最大偏差 0.0022)。该人群为高 BMI 队列: 男胎 BMI 中位数 32.3, 79.2% 的样本 $BMI \geq 30$ 、15.7% ≥ 35 ; 孕周覆盖 11.0–27.7 周。86.5% 的男胎检测达到 4% 阈值; 男胎数据另有 126 条非整倍体标记、38 例新生儿不健康记录 (仅用于描述, 问题 4 按题意使用女胎 AB 列)。女胎 67 条记录带非整倍体标记 (T18 计 46 次、T13 计 23 次、T21 计 13 次, 含组合), 且同一孕妇的不同检测可能标记不一致 (43 名), 故标签为“逐次检测的判定结果”, 交叉验证按孕妇分组以避免泄漏。

5 问题 1: Y 染色体浓度与孕周、BMI 的关系模型

5.1 相关特性

Pearson 相关 (表 1) 显示: Y 浓度与孕周显著正相关 ($r = 0.105$)、与 BMI、体重、身高、年龄显著负相关 ($r = -0.168, -0.191, -0.103, -0.112$), 与 X 染色体浓度强正相关 ($r = 0.481$, 两者同为胎儿游离 DNA 份额的体现)。同一孕妇重复测量的组内相关系数 $ICC = 0.24$, 提示必须使用混合效应模型。

表 1: Y 浓度与各指标的相关性

指标	孕周	BMI	体重	年龄	X 浓度
Pearson r	0.105	-0.168	-0.191	-0.112	0.481
p 值	5.4×10^{-4}	3.0×10^{-8}	2.5×10^{-10}	2.4×10^{-4}	3.3×10^{-63}

5.2 模型建立与选择

候选模型在统一观测尺度 (浓度 C) 下以雅可比校正的对数似然比较: 线性模型 M1、对数线性 M2 ($\ln C = \beta_0 + \beta_1 G + \beta_2 B$)、双对数 M3、含交互 M4、含二次项 M5/M6。结果显示 BMI 的二次项高度显著 (M6 vs M2 似然比 $\chi^2 = 24.1$, $p = 9 \times 10^{-7}$), 交互项不显著 ($\chi^2 = 0.43$, $p = 0.51$)。BIC 选择

$$\ln C = -6.319 + 0.0133 G + 0.2356 B - 0.00398 B^2 + \varepsilon, \quad \varepsilon \sim N(0, 0.209), \quad (1)$$

全部系数 $p < 10^{-4}$ (HC3 稳健标准误), $R^2 = 0.065$ 。残差 Breusch-Pagan 检验 $p = 0.74$ (对数尺度无显著异方差); Jarque-Bera 拒绝正态 (尾部偏厚), 故推断一律采用稳健标准误; $VIF \approx 1.02$ 无共线性。由于 R^2 较低而 ICC 显著, 进一步拟合随机截距混合模型

$$\ln C_{im} = -2.665 + 0.0433 G_{im} - 0.0223 B_{im} + u_m + \varepsilon_{im}, \quad u_m \sim N(0, 0.159), \quad \varepsilon \sim N(0, 0.061), \quad (2)$$

对 OLS 的似然比 $\chi^2 = 669$ ($p \approx 10^{-148}$)。两式含义互补: 式 (1) 为群体规划提供 C 关于 (G, B) 的预测曲面 (图 2 中 4% 等值线即问题 2 的达标边界); 式 (2) 揭示个体内纵向规律——随访同一孕妇时孕周每增 1 周浓度相对提高 $e^{0.0433} - 1 \approx 4.4\%$, BMI 每增 1 单位相对下降 2.2%。BMI

二次项顶点位于 $B^* = 0.2356/(2 \times 0.00398) \approx 29.6$ ，即本高 BMI 队列中浓度随 BMI 先升后降，提示仅按线性“BMI 越高浓度越低”分组会失真，这正是问题 2 需要数据驱动分组的原因。




图 1: Y 浓度与孕周、BMI 的散点及模型曲线 (红色虚线为 4% 达标线)




图 2: 模型预测的 Y 浓度曲面与 4% 达标等值线 (红)

6 问题 2: BMI 分组与最佳 NIPT 时点

6.1 达标概率的验证

对 BMI 组 $\times$ 孕周段统计经验达标比例，与模型 $\Phi((\mu(t, b) - \ln 0.04)/s)$ 对照 ($s^2 = \tau^2 + \sigma^2 = 0.220$)，22 个有效格子中模型与经验值平均偏差约 4 个百分点 (例如 $[10, 12]$ 周 $\times$ BMI $[28, 32]$: 经验 0.886 vs 模型 0.871; $[12, 14] \times [32, 36]$: 0.888 vs 0.847)，可用于时点优化。

6.2 期望风险递推与分组优化

给定首次检测时点 t_0 ，有效概率 $p_{\text{valid}}(t, b) = (1 - p_{\text{fail}}(t)) \Phi((\mu(t, b) - \ln 0.04)/s)$ ；无效则 δ 周后复查，期望风险反向递推：

$$R(t) = p_{\text{valid}}(t) w(t) + (1 - p_{\text{valid}}(t)) (\lambda + R(t + \delta)), \quad t \leq 30. \quad (3)$$

以带最小样本量约束的一维动态规划在 BMI 离散格 (0.5) 上搜索 $K = 4, 5, 6$ 组的最优区间划分，目标为组内共用时点下 $\sum R$ 最小。结果显示 $K = 4, 5, 6$ 的总风险几乎相同 (人均 1.0442)，内部细切分 (29.0/29.5) 无实际意义，故合并为可执行的三组方案 (表 2)。Bootstrap (200 次聚类重抽样) 显示中位切点约 29 与 38，95% 区间 [28.5, 31]、[30, 39.5]，高 BMI 边界稳健。

表 2: 推荐的 BMI 分组、最佳时点与风险指标

组别	BMI 区间	样本数	最佳时点 t^*	期望风险	平均检测次数	达标率
G1	[20.5, 28.5]	74	10.0 周	1.026	1.27	85.1%
G2	(28.5, 38.0]	959	10.0 周	1.028	1.28	83.9%
G3	(38.0, 47.0]	42	10.25 周	1.458	2.23	53.5%

结果解读：(1) 由于 10–12 周经验达标率已达 82–89%，且复查可落在低风险带内，**最优首次检测时点被压缩到可检测窗口起点 10 周**，这与“尽早发现”的临床原则一致；题给经验五分组的人均风险 1.044 与优化方案相同，说明简单经验分组的主要缺陷不在时点而在对高 BMI 人群的识别不足。(2) G3 组风险比 G1/G2 高约 42%、平均需 2.2 次检测、近半数在窗口内难以达标 (BMI=45 时模型预测 50% 分位达标时间超出 26 周)，应列为重点管理人群：10–10.5 周首检、间隔 2 周复查，两次未达标即联合侵入性诊断。经验最早达标周数 (左截断下) 亦显示 BMI 36–40 组中位 16.7 周、40+ 组 20.1 周，显著晚于低 BMI 组的 12.8–13.3 周，与模型一致。




图 3: 各 BMI 组达标概率：模型曲线与经验比例 (点)




图 4: 不同首次检测时点的期望风险（空心点为组内最优）




图 5: 数据驱动分组的 BMI 分布与组内最佳时点

6.3 检测误差与假设的敏感性

在浓度测量误差变异系数 0–20% 下重算：各组最优时点不变，人均风险由 1.0442 缓升至 1.0467 (+0.24%)；测序失败早期分量 p_{early} 由 0 升至 0.2 时风险由 1.037 升至 1.065，时点仍不变；复查间隔 $\delta = 1, 2, 3$ 周对应风险 1.023/1.044/1.090——**缩短复查间隔是降低高 BMI 孕妇风险最有效的杠杆**。即：检测误差主要抬高期望风险水平，而不改变”及早首检、高 BMI 加密复查”的策略（图 6）。




图 6: 检测误差敏感性: 左为各组最优时点, 右为最小期望风险

7 问题 3: 综合多因素的分组与时点

7.1 扩展模型

在浓度模型中引入体重 W 、身高 H 、年龄 A 。统一尺度似然比较选择

$$\ln C = -4.711 + 0.0136 G + 0.0537 W - 0.00037 W^2 + 0.0015 H - 0.0111 A + \varepsilon, \quad R^2 = 0.082, \quad (4)$$

其中孕周、体重 (线性 + 二次)、年龄显著 ($p = 3.5 \times 10^{-5}$, 0.020, 0.006, 0.003), 身高不显著 ($p = 0.70$) ——与”母体血容量/体重稀释胎儿游离 DNA”的机制一致, 身高仅提供信息而无独立效应。备选模型 E1 (式 (1)+ 年龄) 中年龄同样显著 (-0.0127 , $p = 9.8 \times 10^{-4}$)。混合效应下个体内的体重、身高、年龄效应均不显著 ($p > 0.13$), 说明这些因素主要解释个体间差异, 而纵向变化仍由孕周主导 ($0.0429/\text{周}$, $p \approx 10^{-73}$)。




图 7: 扩展模型系数及 95% CI (标准化前)

7.2 分组、达标比例与个体化

以扩展模型对每个个体计算风险曲线后再做动态规划，所得分组与问题 2 一致（人均风险 1.047 vs 1.044），各组最佳时点不变；个体化最优时点 t_i^* 与组内统一时点几乎无差别（组内标准差 ≈ 0 ），即在本队列中按 BMI 三组执行统一时点不会带来可察觉的损失。达标比例：G2 组模型 83.9%，经验 ($t^* \pm 1.5$ 周窗口, $n = 18$) 88.9%；G3 组模型 56.7%，与经验 ($n = 1$, 参考) 方向一致。误差敏感性同问题 2（CV 20% 时风险 1.050，时点不变，图 9）。

表 3: 扩展模型下的分组结果

组别	BMI 区间	n	t^*	期望风险	模型达标率	经验达标率
G1	[20.5,28.5]	74	10.0	1.023	86.2%	—
G2	(28.5,38.0]	959	10.0	1.029	83.9%	88.9%
G3	(38.0,47.0]	42	10.25	1.524	56.7%	—

结论：纳入身高、体重、年龄后，“BMI 三组 + 窗口起点首检 + 高 BMI 加密复查”的建议保持不变；年龄与体重的作用体现在风险分层解释而非改变时点。




图 8: 个体化最优时点（散点）与组内统一时点（红线）




图 9: 扩展模型下检测误差敏感性

8 问题 4: 女胎异常的判定方法

8.1 标签与基线

以 AB 列为判定结果 (67 条异常: T18 最多)。经典规则 $|Z_k| \geq 3$ 的灵敏度仅 0–6% (表 4), 因为本数据异常样本的 Z 值多数未达到 3 (如 T21 异常行 Z_{21} 均值 -0.16), 单染色体阈值规则失效, 必须多指标融合。

8.2 分类模型 (按孕妇分组的分层交叉验证)

特征取 13/18/21/X 的 Z 值、X 浓度、总及各染色体 GC 含量、BMI、孕周、年龄、读段数与比对/重复/过滤比例。结果 (表 4): 对“任一异常”, logistic 回归 AUC 0.781 (Youden 阈值 0.114 时灵敏度 0.687、特异度 0.768), 随机森林 0.761、梯度提升 0.748; 逐染色体中 T13 以随机森林最佳 (AUC 0.834), T18 约 0.79; **T21 的 AUC 仅约 0.5**, 当前特征不含其可学习信号, 如实披露并建议该类样本送其他平台或侵入性复核。

表 4: 基线 $|Z|$ 规则与机器学习 (分组 CV) 对比

方法	目标	AUC	灵敏度	特异度
$ Z \geq 3$ 规则	任一	—	0.060	0.924
Logistic	任一	0.781	0.687	0.768
随机森林	T13	0.834	0.783	0.801
Logistic	T18	0.790	0.783	0.751

8.3 可解释判定规则

以标准化特征拟合 logistic 得分

$$s = \beta_0 + \sum_k \beta_k \frac{x_k - \mu_k}{\sigma_k}, \quad P = \frac{1}{1 + e^{-s}}, \quad (5)$$

全数据 AUC 0.861; Youden 阈值 0.166 处灵敏度 0.716、特异度 0.883 (泛化性能以 CV 的 0.78 为准)。显著因素 ($p < 0.05$): X 染色体浓度 ($\beta = -0.92$, $p = 2.5 \times 10^{-5}$)、21 号 GC 含量 (-4.25 , $p = 5.2 \times 10^{-7}$)、13 号 GC 含量 ($+3.32$, $p = 2.2 \times 10^{-3}$)、X 的 Z 值 (-0.35 , $p = 0.039$)、年龄 (-0.43 , $p = 0.045$)、被过滤读段比例 ($+0.30$, $p = 0.011$)。随机森林重要性同样以 X 浓度 (0.24)、13 号 GC (0.10)、BMI (0.08) 居前三。生物学上: 异常判定与”胎儿游离 DNA 份额偏低 (X 浓度低) + 测序/GC 分布异常”相伴, 提示数据中的非整倍体标记部分源于低浓度下的测序质量扰动, 判定规则据此把 Z 值、GC 含量、浓度与质量指标融合。

建议的判定流程: 逐染色体计算得分 s_k (logistic, 特征以对应 Z_k 、 GC_k 、X 浓度为主), $P_k \geq$ 阈值判为该号染色体疑似非整倍体; 任一 P_k 超阈或综合得分 $P \geq 0.17$ 判为”异常待确认”, 结合 X 浓度与过滤比例评估可信度; 对判异常者 2 周内复查或转侵入性诊断; T21 因特征信号不足一律联合复核。




图 10: 13/18/21 号染色体 Z 值按标签着色: 异常样本多未越出 ± 3 虚线




图 11: 各判定目标的 ROC 曲线 (按孕妇分组 CV)




图 12: 综合判定 logistic 比值比 (标准化特征)




图 13: 判定概率校准图 (CV 概率)

9 模型评价

优点: (1) 全部推断使用稳健标准误与按孕妇分组的交叉验证, 重复测量结构由混合效应显式建模; (2) 风险模型把题目定性的”低/高/极高”风险连续化并给出可复核的递推式, 结论经误差、失败率、复查间隔三重敏感性验证; (3) 分组采用带最小样本量约束的动态规划并以 bootstrap 报告切点不确定性; (4) 对 T21 不可学习、标签为逐次判定等局限如实披露。**局限:** (1) R^2 较低 (0.06–0.08), 浓度个体差异大, 时点建议应结合个体复查而非单次预测; (2) 测序失败函数与复查代价为假设参数, 虽经敏感性分析仍需在真实成本下校准; (3) 女胎标签为 NIPT 自身判定且新生儿均健康, 规则学习的是”检测判定”而非出生结局; (4) 10 周时点的外推依赖模型在 10–12 周的良好校准。

10 结论

(1) Y 浓度随孕周上升、随 BMI 先升后降 (顶点约 29.6), 对数线性二次模型与混合效应模型均高度显著; (2) 推荐三组方案: $BMI \leq 28.5$ 、 $28.5-38$ 、 > 38 , 最佳首检时点分别为 10、10、10-10.5 周, 高 BMI 组间隔 2 周复查、两次未达标转侵入性诊断; 检测误差不改变该策略; (3) 加入体重、身高、年龄后结论稳健, 年龄与体重解释个体间差异; (4) 女胎判定应采用多指标 logistic/树模型融合 (AUC 0.78-0.83), 摒弃单一 $|Z| \geq 3$ 规则, T21 需联合复核。

参考文献

- [1] Rolnick N, et al. Influence of body mass index on fetal fraction increase with gestation and cell-free DNA test failure. *Obstetrics & Gynecology*, 2018.
- [2] Cell-Free Fetal DNA Screening Analysis in Korean Pregnant Women: Six Years of Experience. *J. Pers. Med.* 2023, 13(10):1468.
- [3] Clinical Feasibility of Early First-Trimester Non-Invasive Prenatal Testing. PubMed 42083549, 2026.
- [4] Lo Y M D, et al. Presence of fetal DNA in maternal plasma and serum. *Lancet*, 1997.

A 可复现性声明

全部计算使用 Python(pandas/NumPy/SciPy/statsmodels/scikit-learn), 脚本位于 `work/scripts/` (q1-q4_analysis.py 等), 中间结果位于 `work/results/`, 图元文件位于 `work/figures/`。分析由 AI 智能体辅助完成, 图表均由数据驱动代码生成, 未使用图像生成模型伪造数值。